

Sprawozdanie WIMU

Łączenie audio i wideo

Mikołaj Chomanski, Bartosz Karolczak, Paweł Niewierowski

Design Proposal

Projekt stanowi implementację modelu zaproponowanego w artykule naukowym pt. „It’s Time for Artistic Correspondence in Music and Video”, w którym autorzy przedstawili innowacyjne podejście do automatycznego dopasowywania ścieżki dźwiękowej do materiału wideo oraz wideo do muzyki oraz przygotowanie praktycznego interfejsu CLI. Głównym celem naszej pracy jest rzetelne odtworzenie wyników bazowych na zupełnie nowym zbiorze danych oraz szczegółowe przetestowanie modelu w zróżnicowanych scenariuszach użytkowych. Aby dostosować tę technologię do wymagań rzeczywistych aplikacji, proponujemy autorskie usprawnienia zwiększające jej elastyczność i precyzję. Kluczowe modyfikacje obejmują przede wszystkim zbadanie wpływu długości fragmentów, na jakie dzielony jest film, na synchronizację z audio, a także wprowadzenie inteligentnej opcji braku przypisania audio w momentach, w których system uzna, że dany segment filmu nie wymaga podkładu muzycznego.

Założenia projektu

Stos technologiczny

- Środowisko i jakość kodu: uv, Python ≥ 3.12 , pytest
- Uczenie maszynowe: PyTorch
- Analiza danych i wizualizacja: Scikit-learn, NumPy, Pandas, Matplotlib
- Śledzenie eksperymentów: MLflow
- Przetwarzanie multimediów: FFmpeg do obsługi plików MP4 i dodawania ścieżki dźwiękowej
- Interfejs użytkownika: CLI, argparse

Planowana funkcjonalność

- Dobieranie ścieżki audio dla podanego pliku MP4.
- Dobieranie ścieżki audio dla wskazanego fragmentu czasowego z podanego pliku MP4.

Zakres eksperymentów

Punktem wyjścia będzie zbiór danych opisany w pozycji [2]. Plan obejmuje zarówno odtworzenie wyników referencyjnych, jak i rozszerzenie badań o scenariusze bardziej zbliżone do praktycznego użycia systemu.

- Odtworzenie eksperymentów z artykułu [1].
- Predykcję dla pojedynczych fragmentów filmu.
- Predykcję dla całego materiału wideo.
- Analizę wpływu długości fragmentów wideo na jakość predykcji.

Przebieg eksperymentów

Postanowiliśmy zbadać zależność jakości predykcji od długości segmentów filmów i ostatecznie przetestowaliśmy dzielenie na segmenty o długości 3s, 5s i 7s. Dodatkowo po eksperymentach dla tych długości postanowiliśmy przeprowadzić również eksperymentu dla podziału na segmenty o długości 4s. Dla każdej długości segmentów testowaliśmy kombinacje transformerów enkodujących o głębokości 3, 4, 5, co daje łącznie 9 kombinacji. Dla każdej z takich kombinacji 5-krotnie wybieraliśmy przypadkowe parametry uczenia i trenowaliśmy takie transformery. Badaliśmy ilość epok, rozmiar batcha, learning rate i jak bardzo learning rate opadał. Każdy wynik każdego z takich testów był nadzorowany z użyciem narzędzi **mlflow**.

Przed samymi testami dzieliliśmy wideo i muzykę na kawałki i kodowaliśmy je z użyciem odpowiednio CLIP oraz CLAP. Dzięki temu sam proces uczenia trwał dużo mniej, a i tak zakładaliśmy, że modele te miały pozostać niezmienione. Takie kawałki były zapisywane jako sekwencje, a podczas treningu dodawany był padding ze samych zer, tak aby wszystkie sekwencje w jednym batchu miały tę samą długość.

Aby ocenić jakość modeli, zastosowaliśmy metrykę Recall@K: sprawdzamy K najbliższych przykładów (jeżeli dopasowujemy muzykę do filmu, to K najbliższych utworów i odwrotnie dla dopasowywania filmu do muzyki) i jeżeli prawdziwy utwór jest w K przykładach, to zaliczamy to jako poprawną predykcję.


Wyniki eksperymentów

Wyniki dla segment_length = 3s

Poniżej przedstawiono wyniki dla pięciu konfiguracji o najlepszej średniej wartości R@1 dla zbioru walidacyjnego. Co ważne, zauważenie, że większość najlepszych testów miała zarówno rozmiar transformera do enkodowania muzyki 4, jak i rozmiar transformera do enkodowania wideo 4. Jeżeli spojrzymy na 20 najlepszych testów (nie umieszczonych tutaj dla czytelności), to również te rozmiary dominują, ale rozmiar 5 pojawia się znacznie częściej niż rozmiar 3. Co ciekawe, wszystkie te modele zostały wytrenowane na rozmiarze batcha 10, co może być spowodowane faktem, że nasz zbiór jest stosunkowo nieliczny. Również dwa pierwsze modele były trenowane przez 80 epok, co podpowiada, że dłuższy trening przynosił znaczące efekty niż krótki, co również jest widoczne, jeżeli przejrzymy wyniki wszystkich modeli. Najlepszy model nie tylko uzyskał dobre wyniki przy R@1, ale również uzyskał idealne wyniki dla R@5, co oznacza, że z dużym powodzeniem może być stosowany w rekomendacji muzyki.

rozmiar batcha	Epoki	Rozmiar Transformera muzycznego	Rozmiar Transformera video	V-> M		M->V		Average	
				R@1	R@5	R@1	R@5	R@1	R@5
10	80	4	5	65	100	61,67	100	63,33	100
10	80	4	4	58,33	98,33	58,33	96,67	58,33	97,5
10	50	5	5	55	90	61,66	91,66	58,33	97,5
10	70	4	4	58,33	90	56,66	91,66	58,33	90,83
10	50	4	4	63,33	98,33	50	93,33	56,66	95,82

Poniżej widnieje przebieg wartości średniej R@1 w trakcie uczenia 5 najlepszych modeli. Jak łatwo zauważyć, przebiegi te mają charakter wykładniczy, ale również wartości mocno oscylują. Znaczących różnic nie widać, ale można zauważyć, że niektóre modele ostatecznie osiągnęły niższe R@1 niż maksymalne, do których dotarły. Patrząc na te wartości, wydaje się, że przestały wzrastać, co sugeruje, że prawdopodobnie w dobrym momencie zatrzymaliśmy trening.




Wyniki dla segment_length = 5s

Poniżej widoczne są wyniki dla pięciu konfiguracji z najlepszą średnią wartością R@1 dla zbioru walidacyjnego. Co ważne, zauważenie, że większość najlepszych testów miała zarówno rozmiar transformera do enkodowania muzyki 3, jak i rozmiar transformera do enkodowania wideo 3. Najlepsze modele zostały wytrenowane dla batchy 10 i 40. Najlepszy model uzyskał dobre wyniki przy R@1 i R@5, jednak wyraźnie gorsze niż w przypadku długości segmentów 3s.

rozmiar batcha	Epoki	Rozmiar Transformera muzycznego	Rozmiar Transformera wideo	V-> M		M->V		Average	
				R@1	R@5	R@1	R@5	R@1	R@5
10	20	4	4	56,66	95	58,33	98,33	57,5	96,66
40	40	4	3	56,66	91,66	58,33	86,66	57,5	89,16
10	70	3	3	56,66	95	53,33	95	55	95
40	80	3	5	53,33	86,66	55	88,33	54,16	87,5
10	30	3	3	53,33	93,33	55	95	54,16	94,16

Poniżej widnieje przebieg wartości średniej R@1 w trakcie uczenia 5 najlepszych modeli. Jak łatwo zauważyć, przebiegi te mają charakter wykładniczy, ale również wartości mocno oscylują. Znaczących różnic nie widać, ale można zauważyć, że niektóre modele ostatecznie osiągnęły niższe R@1 niż maksymalne, do których dotarły.




Wyniki dla segment_length = 7s

Poniżej widoczne są wyniki dla pięciu konfiguracji z najlepszą średnią wartością $R@1$ dla zbioru walidacyjnego. Większość najlepszych testów miała rozmiar transformera do enkodowania muzyki 5, a rozmiar transformera do enkodowania wideo 3. Najlepsze modele zostały wytrenowane dla batchy 10 i 30. Najlepszy model uzyskał najniższe wyniki spośród testowanych długości segmentów, przy $R@1$ około 50% a $R@5$ nieprzekraczającym 95%.

rozmiar batcha	Epoki	Rozmiar Transformera muzycznego	Rozmiar Transformera wideo	V-> M		M->V		Average	
				R@1	R@5	R@1	R@5	R@1	R@5
10	20	2	3	50	95	53,33	91,67	51,67	93,33
10	50	5	5	50	91,67	50	90	50	90,83
10	60	4	3	50	91,67	50	91,67	50	91,67
30	50	5	4	48,33	90	51,67	86,67	50	88,33
30	60	5	3	46,67	88,33	51,67	91,67	49,17	90


Poniżej widnieje przebieg wartości średniej $R@1$ w trakcie uczenia 5 najlepszych modeli. Jak łatwo zauważyć, przebiegi te mają charakter wykładniczy, ale również wartości mocno oscylują. Znaczących różnic nie widać, ale można zauważyć, że niektóre modele ostatecznie osiągnęły niższe $R@1$ niż maksymalne, do których dotarły.



Wyniki dla segment_length = 4s

Pomimo tego, że patrząc na wyniki dla długości segmentów 3s i 5s, głównym wnioskiem nasuwającym się jest to, że wartość pomiędzy nimi powinna dawać najlepsze wyniki i najlepszą stabilność, wyniki dla 4s uzyskane przez nas okazały się jednak dużo gorsze. Rozmiary najlepszych modeli są podobne dla tych w eksperymentach z długością 3s, ale pomimo tego, że fragmenty 4s powinny nieść więcej informacji, wyniki są gorsze. Co jest stałe między pozostałymi testami i tym to mniejsze rozmiary batchy miały większe szanse osiągnąć lepsze wyniki. Dwukrotnie przeprowadzaliśmy testy dla tej długości segmentów, ale nie zauważyliśmy poprawy.

rozmiar batcha	Epoki	Rozmiar Transformera muzycznego	Rozmiar Transformera video	V-> M		M->V		Average	
				R@1	R@5	R@1	R@5	R@1	R@5
10	40	5	5	60	95	51,66	98,33	55,8	96,67
10	50	5	4	53,33	95	53,33	95	53,33	95
10	60	5	4	53,33	95	53,33	90	53,33	93,33
20	30	4	4	56,66	85	5	91,66	53,33	92,5
10	80	5	5	53,33	98,33	51,67	95	52,5	93,33



Wnioski

Zdecydowanie najważniejszym wnioskiem jest odwrotnie proporcjonalna zależność między długością segmentu a skutecznością predykcji.

- Segmenty 3-sekundowe przyniosły zdecydowanie najlepsze rezultaty, osiągając średnie R@1 na poziomie ponad 63% oraz perfekcyjne wyniki R@5 (100%).
- Segmenty 5-sekundowe przyniosły nieco gorsze rezultaty, zauważono spadek skuteczności (najlepsze średnie R@1 spadło do 57,5%).
- Segmenty 7-sekundowe przyniosły najłabsze rezultaty spośród wszystkich badanych wariantów, z maksymalnym średnim R@1 na poziomie 51,67% i R@5 spadającym w okolice 88-93%.

Krótsze okna czasowe pozwalają modelom na skuteczniejsze wychwytywanie nagłych zmian, dynamiki i detali audiowizualnych. W dłuższych segmentach (5s i 7s) specyficzne cechy prawdopodobnie ulegają rozmyciu lub "uśrednieniu", co utrudnia modelom znalezienie unikalnych powiązań między modalnościami. Ale, co ciekawe, R@1 dużo bardziej oscylowała dla modeli wytrenowanych na krótszych fragmentach. Może to być spowodowane tym, że film jest po prostu dzielony na większą liczbę fragmentów albo tym, że fragmenty zawierały mniej kontekstu, przez co były potrzebne większe sieci oraz dłuższy trening.

We wszystkich długościach segmentów absolutnie dominował rozmiar batcha równy 10. Jest to zjawisko typowe dla mniejszych zbiorów danych, gdzie mniejsze paczki wprowadzają więcej szumu do gradientu, co paradoksalnie pomaga modelowi uniknąć utknięcia w minimach lokalnych i ułatwia generalizację. Krótsze segmenty (3s) faworyzowały nieco głębsze sieci (rozmiar 4 i 5) oraz wymagały dłuższego treningu (najlepsze wyniki przy 70-80 epokach). Z kolei dla dłuższych okien (5s i 7s) płytsze modele (rozmiar 2 lub 3) okazywały się wystarczające, a dłuższy trening często nie przynosił poprawy. Bazując na tych wynikach, można stwierdzić, że długość fragmentów równa 3s jest najlepsza, jeżeli chcemy uzyskać jak najlepsze wyniki, a długość 5s jest najlepsza, gdy zależy nam na stabilności wyników w procesie uczenia. Co ciekawe, pomimo wniosków, które mogłyby być oczywiste, że długość segmentów pomiędzy 3s i 5s będzie najlepsza, wyniki dla 4s były znacznie gorsze. Może to wynikać z tego, że przy 4s mamy nadal dużo kawałków tak jak dla 3s, ale nie mamy też w tych kawałkach tyle informacji, ile jest w 5s.

Porównanie z artykułem

Uzyskane przez nas wyniki są znacznie lepsze od wyników uzyskanych w artykule "It's Time for Artistic Correspondence in Music and Video", nawet dla najdłuższych segmentów. Autorzy uzyskali maksymalne R@1 w wysokości około 19% i R@5 w wysokości około 22%, co jest znacznie gorzej od tego, co udało nam się osiągnąć. Jednym z powodów może być wykorzystanie przez nas innego enkodera wideo, który może wyciągać więcej cech ważnych przy dopasowywaniu. Kolejnym czynnikiem wpływającym na jakość jest wykorzystanie mniejszego zbioru danych. Pomimo tego, że modele świetnie uczyły się na tych danych, to było ich nadal mało, więc była mniejsza szansa na pomyłkę. Warto natomiast zwrócić uwagę na to, że udowodniliśmy, że zmniejszenie długości segmentów pozytywnie wpływa na jakość sugestii, więc prawdopodobnie 5 s zastosowanych przez autorów artykułów nie jest optymalną długością segmentów.

Przykład użycia z CLI

Uruchomienie CLI i proces generowania segmentów z plików audio i wideo, segmenty zostają zapisywane do tymczasowego folderu:

```
$ or run python cli.py videoMusic --video "data/raw/videos_3kH2ITV01.mp4" --music-db "data/raw/audio" --video-weights "outputs\20260518222409_mysterious-fam-659\video_transformer.pth" --music-weights "outputs\20260518222409_mysterious-fam-659\music_transformer.pth"

-> Building embeddings for the music database... Found 300 files.
Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
Loading weights: 100% | 447/447 [00:00:00.00, 71592.10it/s]
Encoding -50-bb850a.wav: 63% | 12/19 [00:00:00.00, 11.34it/s]
```

Rozpoczęcie łączenia segmentów podanego pliku wejściowego (wideo) z segmentami plików audio w tymczasowym folderze:

```
[Time 000.0s - 005.0s] -> rcYra15Kt3g.wav #014 (score=0.6531) | 1/24 [00:01:00:20, 1.23it/s]
Matching segments: 4% |
[Time 005.0s - 010.0s] -> u6safoKu1VA.wav #088 (score=0.6440) | 2/24 [00:01:00:20, 1.08it/s]
Matching segments: 8% |
[Time 010.0s - 015.0s] -> ia32ReZf85A.wav #002 (score=0.6345) | 3/24 [00:02:00:17, 1.22it/s]
Matching segments: 12% |
[Time 015.0s - 020.0s] -> ia32ReZf85A.wav #002 (score=0.6258) | 4/24 [00:03:00:15, 1.27it/s]
Matching segments: 17% |
[Time 020.0s - 025.0s] -> rcYra15Kt3g.wav #014 (score=0.6365) | 5/24 [00:04:00:14, 1.33it/s]
Matching segments: 21% |
[Time 025.0s - 030.0s] -> rcYra15Kt3g.wav #014 (score=0.6329) | 6/24 [00:04:00:13, 1.38it/s]
Matching segments: 25% |
[Time 030.0s - 035.0s] -> rcYra15Kt3g.wav #014 (score=0.6416) | 7/24 [00:05:00:12, 1.37it/s]
Matching segments: 29% |
[Time 035.0s - 040.0s] -> rcYra15Kt3g.wav #014 (score=0.6392) | 8/24 [00:06:00:11, 1.41it/s]
Matching segments: 33% |
[Time 040.0s - 045.0s] -> e1FKWFFeVg.wav #001 (score=0.6521) | 9/24 [00:06:00:10, 1.37it/s]
Matching segments: 37% |
[Time 045.0s - 050.0s] -> rcYra15Kt3g.wav #014 (score=0.6420) | 10/24 [00:07:00:09, 1.41it/s]
Matching segments: 41% |
[Time 050.0s - 055.0s] -> ia32ReZf85A.wav #002 (score=0.6355) | 11/24 [00:08:00:09, 1.40it/s]
Matching segments: 45% |
[Time 055.0s - 060.0s] -> rcYra15Kt3g.wav #014 (score=0.6308) | 12/24 [00:09:00:08, 1.41it/s]
Matching segments: 50% |
[Time 060.0s - 065.0s] -> d1AWvLslyok.wav #030 (score=0.6345) | 13/24 [00:09:00:07, 1.44it/s]
Matching segments: 54% |
[Time 065.0s - 070.0s] -> rcYra15Kt3g.wav #014 (score=0.6363) | 14/24 [00:10:00:06, 1.45it/s]
Matching segments: 58% |
[Time 070.0s - 075.0s] -> d1AWvLslyok.wav #030 (score=0.6445) | 15/24 [00:11:00:06, 1.46it/s]
Matching segments: 62% |
[Time 075.0s - 080.0s] -> d1AWvLslyok.wav #030 (score=0.6451)
```

Zakończenie procesu łączenia segmentów, CLI zwraca plik wyjściowy mp4 z połączonym wideo z audio:

```
Matching segments: 71% | 17/24 [00:12:00:05, 1.38it/s]
[Time 085.0s - 090.0s] -> ia32ReZf85A.wav #002 (score=0.6361) |
Matching segments: 74% | 18/24 [00:13:00:04, 1.41it/s]
[Time 090.0s - 095.0s] -> d1AWvLslyok.wav #030 (score=0.6348) |
Matching segments: 79% | 19/24 [00:13:00:03, 1.37it/s]
[Time 095.0s - 100.0s] -> rcYra15Kt3g.wav #014 (score=0.6444) |
Matching segments: 83% | 20/24 [00:14:00:02, 1.42it/s]
[Time 100.0s - 105.0s] -> rcYra15Kt3g.wav #014 (score=0.6387) |
Matching segments: 88% | 21/24 [00:15:00:02, 1.47it/s]
[Time 105.0s - 110.0s] -> ia32ReZf85A.wav #002 (score=0.6370) |
Matching segments: 92% | 22/24 [00:15:00:01, 1.49it/s]
[Time 110.0s - 115.0s] -> d1Y8SQudy0.wav #008 (score=0.6391) |
Matching segments: 96% | 23/24 [00:16:00:00, 1.54it/s]
[Time 115.0s - 120.0s] -> d1Y8SQudy0.wav #002 (score=0.6335) |
Matching segments: 100% | 24/24 [00:17:00:00, 1.41it/s]

-> Rendering final video file...
Done. Output written to: _3kH2ITV01_out.mp4
```

Nagranie

[av-matching-model-film.mp4](#)

Bibliografia

1. Surís, Dídac, et al. *It's Time for Artistic Correspondence in Music and Video.* Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022. [arXiv:2206.07148](https://arxiv.org/pdf/2206.07148)
2. Tian, Zeyue, et al. *VidMuse: A Simple Video-to-Music Generation Framework with Long-Short-Term Modeling.* Proceedings of the Computer Vision and Pattern Recognition Conference, 2025. [arXiv:2406.04321](https://arxiv.org/abs/2406.04321)
3. Radford, Alec, et al. *Learning Transferable Visual Models from Natural Language Supervision.* International Conference on Machine Learning, PMLR, 2021. [PMLR v139](https://proceedings.mlr.press/v139/radford21a)

4. Lee, Jongpil, et al. *Metric Learning vs Classification for Disentangled Music Representation Learning.* arXiv preprint arXiv:2008.03729, 2020.
[arXiv:2008.03729](https://arxiv.org/abs/2008.03729)