

It's Time for Artistic Correspondence in Music and Video https://arxiv.org/pdf/2206.07148	Główny artykuł na którym bazujemy nasz projekt, zawiera opis architektury i przedstawia metryki Zbiór danych oraz kod nie zostały udostępnione Metryki użyte w porównaniu to recall@K (czy przykład znajduje się w top 1, 5 lub 10 przykładów najbliższych) oraz Medial rank (określa, na którym miejscu w rankingu odległości najczęściej ląduje ten właściwy, poszukiwany przez nas wynik.) Sam model trenowano na 8 kartach RTX 2080
VidMuse: A Simple Video-to-Music Generation Framework with Long-Short-Term Modeling https://arxiv.org/abs/2406.04321	Artykuł skupia się na generacji muzyki z wykorzystaniem wideo jako warunku. Z tego artykułu wykorzystaliśmy tylko zbiór danych którego część została udostępniona Zbiór składa się z kawałków wideo i audio o takich samych nazwach
Learning Transferable Visual Models from Natural Language Supervision. https://proceedings.mlr.press/v139/radford21a	Artykuł ten prezentuje model łączący przestrzeń obrazów i tekst opisującego te obrazy. W naszej pracy model ten może zostać wykorzystany do kodowania kawałków wideo. Sam artykuł udostępnia pretrenowany model CLAP (na huggingface), więc można go zastosować do wielu zadań. Sama sieć jest duża i była trenowana na dużym zbiorze danych z 15 milionami elementów. Sam model był trenowany z wykorzystaniem uczenia kontrastowego
Metric Learning vs Classification for Disentangled Music Representation Learning. https://arxiv.org/abs/2008.03729	Artykuł ten prezentuje model CLAP, czyli model do otrzymywania reprezentacji muzyki (CLIP dla muzyki). Model ten jest udostępniony na huggingface. Model radzi sobie ze zmienną długością plików dźwiękowych dzięki mechanizmowi fuzji cech i pozwala na ekstrakcję reprezentacji cech dla dowolnego dźwięku. Do oceny zostały wykorzystane Recall@K oraz średnia pozycja w rankingu. Tak samo jak CLIP używał uczenia kontrastowego. Jest lepszym (i nowocześniejszym) rozwiązaniem niż DeepSim w przypadku naszego projektu.